Neural Networks and Deep Learning

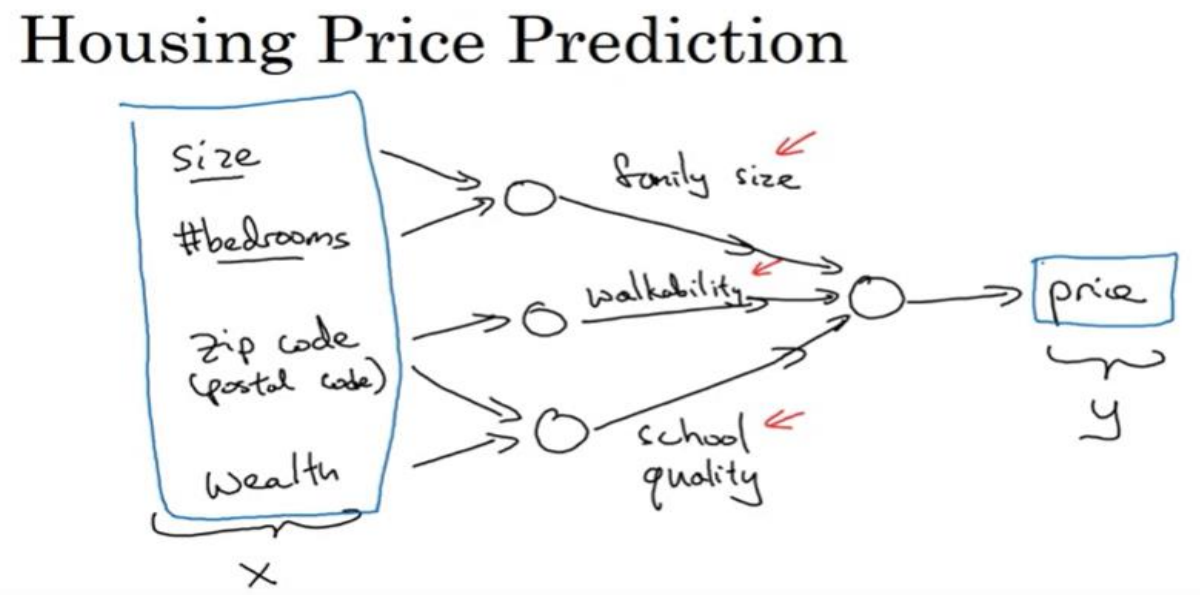

입력 값의 특성 : 집의 크기, 침실 수, 우편번호, 이웃집의 재산

신경망의 역할은 y값을 예측하는 것, 신경망 중간에 있는 레이어는 밀도가 높다.

[Supervised Learning]

부동산 애플리케이션, 온라인 광고 ; 보편적인 표준 신경망 아키텍처 (Standard NN)

이미지 애플리케이션 ; CNN

언어, 오디오 ; 시간에 따라 재생되기 때문에 1차원 시계열 또는 1차원 시간 시퀀스 => RNN

자율주행 ; 하이브리드 신경망 아키텍처

[퀴즈]

Which of the following are examples of unstructured data? Choose all that apply.

- [x] Sound files for speech recognition.

✓ Correct
Yes, audio is an example of "unstructured" data.

- [x] Images for bird recognition.

✓ Correct
Yes, images are an example of "unstructured" data.

- [x] Text describing size and number of pages of books.

✓ Correct
Yes, text documents are examples of "unstructured" data.

- [ ] Information about elephants' weight, height, age, and the number of offspring.

Which of the following are examples of structured data? Choose all that apply.

- [ ] A set of audio recordings of a person saying a single word.
- [x] A dataset of weight, height, age, the sugar level in the blood, and arterial pressure.

✓ Correct
Yes, this data can be presented in a table. This is an example of "structured" data.

- [x] A dataset with zip code, income, and name of a person.

✓ Correct
Yes, this data can be presented in a table. This is an example of "structured" data.

- [ ] A dataset with short poems.

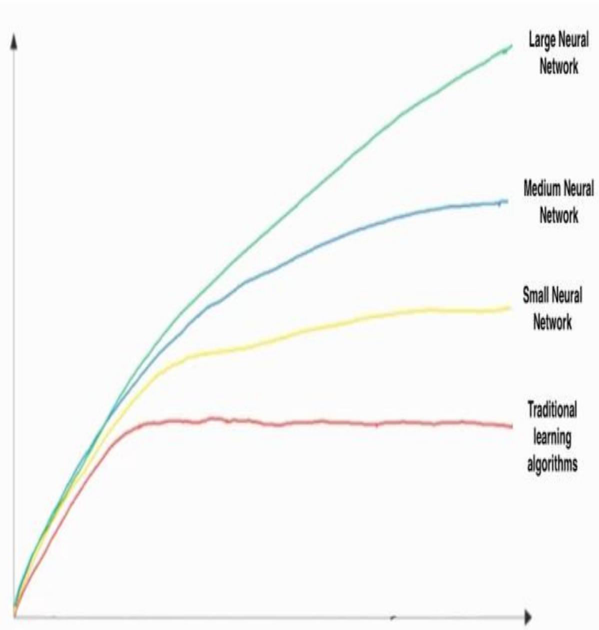

. Assuming the trends described in the previous question's figure are accurate (and hoping you got the axis labels right), which of the following are true? (Check all that apply.)

- [x] Increasing the size of a neural network generally does not hurt an algorithm's performance, and it may help significantly.

✓ Correct
Yes. According to the trends in the figure above, big networks usually perform better than small networks.

- [ ] Decreasing the training set size generally does not hurt an algorithm's performance, and it may help significantly.
- [ ] Decreasing the size of a neural network generally does not hurt an algorithm's performance, and it may help significantly.
- [x] Increasing the training set size generally does not hurt an algorithm's performance, and it may help significantly.

✓ Correct
Yes. Bringing more data to a model is almost always beneficial.

Why is an RNN (Recurrent Neural Network) used for machine translation, say translating English to French? (Check all that apply.)

- [ ] It is strictly more powerful than a Convolutional Neural Network (CNN).
- [x] It is applicable when the input/output is a sequence (e.g., a sequence of words).

✓ Correct
Yes. An RNN can map from a sequence of english words to a sequence of french words.

- [ ] RNNs represent the recurrent process of Idea->Code->Experiment->Idea->....
- [x] It can be trained as a supervised learning problem.

✓ Correct
Yes. We can train it on many pairs of sentences x (English) and y (French).

2. Neural Network Basics

[로지스틱 회귀] ; 이진 분류

입력 이미지가 64 X 64 픽셀의 경우 빨/초/파란색 픽셀의 채도값에 해당하는 3개의 64 X 64 행렬 -> 픽셀들의 채도값을 특징 벡터로 바꾸기 위해 픽셀값 모두를 하나의 입력 특징 벡터 x에 펼쳐 -> 이 벡터 x의 전체 차원은 64 * 64 * 3 = 12288 (nx = 12288)

훈련 데이터 행렬 X는 <u>nx X m</u> 차원을 가짐 (m : 훈련데이터셋 수)

타겟 데이터 행렬 Y는 <u>1 X m</u> 차원을 가짐

$$X = \underbrace{\begin{bmatrix} | & | & & | \\ x^{(1)} & x^{(2)} & \cdots & x^{(m)} \\ | & | & & | \end{bmatrix}}_{m} \Big\updownarrow n_x \qquad Y = [y^{(1)} \; y^{(2)} \cdots, y^{(m)}]$$

시그모이드

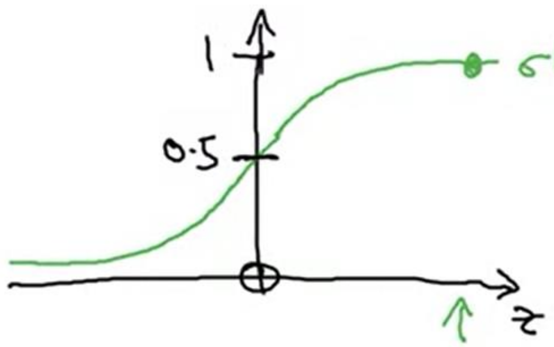

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

손실함수 : 실제 라벨이 y일 때 출력 ŷ이 얼마나 좋은지 측정하기 위해 정의해야 하는 함수

$$\mathcal{L}(\hat{y}, y) = -\left(y \log \hat{y} + (1-y)\log(1-\hat{y})\right)$$

IF y = 1이면, 손실함수 = -log ŷ => 손실함수 값이 작으려면 log ŷ을 크게 하기를 원하고, 즉 ŷ도 크게 하기를 원한다. 하지만, ŷ는 시그모이드 함수 출력이기에 1이 될 수 없다. 가능한 한 크게 ŷ을 원하지만 1보다 클 수는 없다.

IF y = 0이면, 손실함수 = -log(1- ŷ) => ŷ을 작게 하기를 원한다.

비용함수

$$J(w,b) = \frac{1}{m}\sum_{i=1}^{m}\mathcal{L}(\hat{y}^{(i)}, y^{(i)}) = -\frac{1}{m}\sum_{i=1}^{m} y^{(i)}\log\hat{y}^{(i)} + (1-y^{(i)})\log(1-\hat{y}^{(i)})$$

비용 함수에 대한 기울기 하강 ; 그레디언트 (경사하강법)

$$w := w - \alpha \frac{dJ(w,b)}{dw}$$

$$b := b - \alpha \frac{dJ(w,b)}{db}$$

알파 : 학습률

[로지스틱 회귀에 대한 기울기 하강]

손실을 줄이기 위해 매개변수 w와 b를 수정

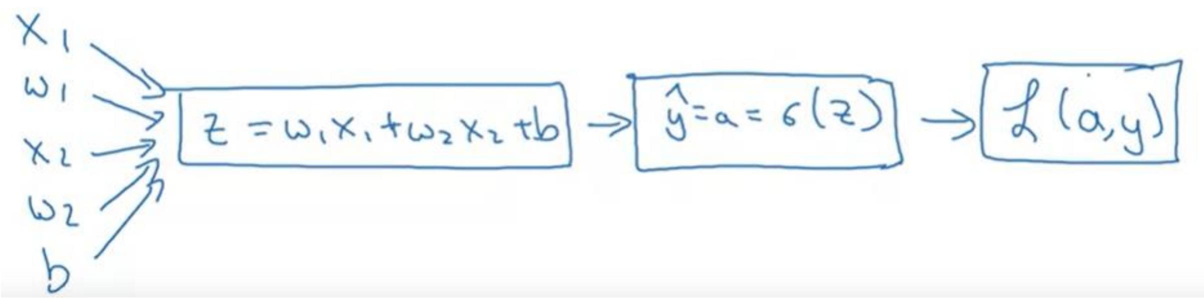

- 딥러닝 알고리즘을 구현할 때 코드에 for 루프가 명시되어 있으면 알고리즘 실행 효율성 (속도)이 떨어진다. 점점 더 큰 데이터셋으로 이동하기에 명시적 for 루프를 사용하지 않고 알고리즘을 구현할 수 있다는 것은 매우 중요하며 훨씬 더 큰 데이터 셋으로 확장할 수 있다. => 벡터화 기법

[코드] Vectorization

for문 대신 np.dot() 사용 / 로지스틱 회귀를 위한 기울기 경사 하강

$$Z = w^T X + b$$
$$= np.dot(w.T, X) + b$$
$$A = \sigma(Z)$$
$$dZ = A - Y$$
$$dw = \frac{1}{m} X dZ^T$$
$$db = \frac{1}{m} np.sum(dZ)$$

$$w := w - \alpha dw$$
$$b := b - \alpha db$$

[코드] 브로드캐스팅

[코드] numpy vector

[Neural Network Representation]

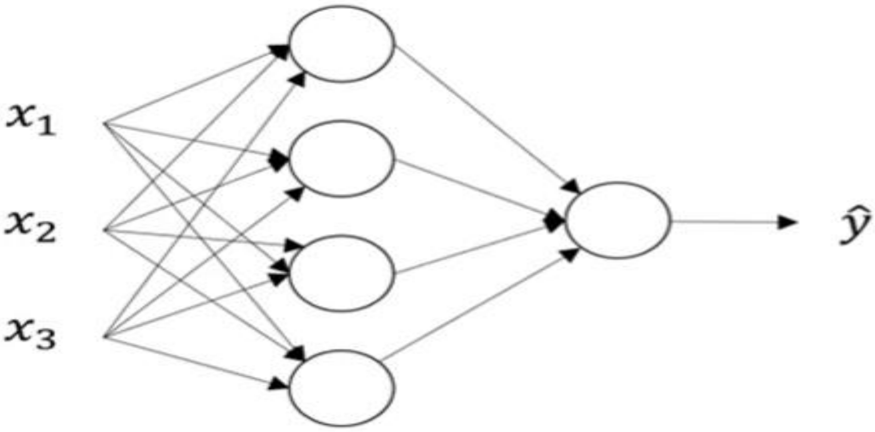

Input layer (a[0] = X)

Hidden layer (a[1])

Output layer (a[2] = y_hat)

⇨ 2 layer NN (input layer은 레이어라고 부르지 않음)

ex) w[1], b[1] -> layer1(Hidden layer)과 관련된 매개 변수
w[1].shape : (4, 3) – 숨겨진 유닛과 layer의 4개 노드가 있으며, 3개의 입력 기능이 있다
b[1].shape : (4, 1) 벡터
w[2]. b[2] -> layer2(Output layer)과 관련된 매개 변수
w[2].shape : (1, 4), b[2].shape : (1, 1) 벡터

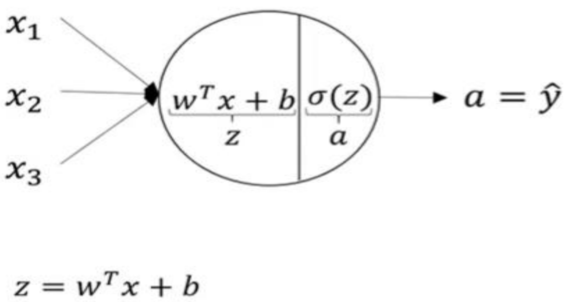

$$z = w^T x + b$$

$$a = \sigma(z)$$

a[l]_i = sigmoid(z[l]_i) l : layer 번호, i : 해당 레이어의 노드

z[1] = W[1] * x + b[1] = W[1] * a[0] + b[1]

a[1] = sigmoid(z[1])   => 활성화 함수

z[2] = W[2] * a[1] + b[2]

a[2] = sigmoid(z[2])   => 활성화 함수

---------------------------단일 훈련------------- X -> a[2] = y_hat / 수직으로 쌓아올림

[m 훈련] ; 수평으로 쌓아올림 => 훈련 전체를 인덱싱

첫 번째 훈련 X(1) -> a[2](1) = y_hat(1) | z[1](1) = W[1] * X(1) + b[1]
두 번째 훈련 X(2) -> a[2](2) = y_hat(2) | z[1](2) = W[1] * X(2) + b[1]

m 번째 훈련 X(m) -> a[2](m) = y_hat(m) | z[1](m) = W[1] * X(m) + b[1]
X(1), X(2) … X(m)은 수평으로 쌓이는 X 행렬

$$X = \begin{bmatrix} | & | & & | \\ x^{(1)} & x^{(2)} & \cdots & x^{(m)} \\ | & | & & | \end{bmatrix}$$

$$A^{[1]} = \begin{bmatrix} | & | & & | \\ a^{[1](1)} & a^{[1](2)} & \cdots & a^{[1](m)} \\ | & | & & | \end{bmatrix}$$

행렬을 수직으로 움직이면 숨겨진 단위 번호에 대한 인덱싱 (hidden units)
행렬을 수평으로 움직이면 여러 훈련 예제 (training examples)

[활성화 함수 g()] ; 레이어마다 다를 수 있다

1) 시그모이드

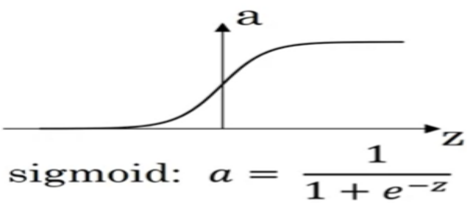

2) 탄젠트 함수

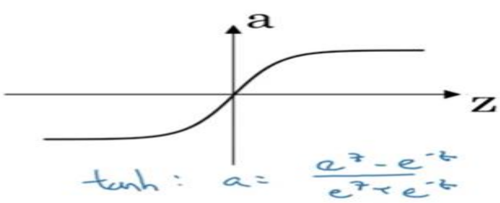

성능 : 1 < 2 ; +1과 -1 사이의 값으로 숨겨진 층에서 나오는 활성화의 평균은 0에 더 가까움

데이터를 중심에 위치시키고, 탄젠트 함수를 사용해 데이터의 평균이 0이 되도록 할 수 있다. 이렇게 하면 다음 레이어에 대한 학습이 조금 더 쉬워진다.

시그모이드는 거의 사용하지 않지만, 출력 레이어에 대한 예외 존재
; y가 0이거나 1이면 y_hat은 -1 ~ +1 이 아니라 0~1 사이에 있는 출력하려는 숫자가 되는 것이 합리적이기에, 이진 분류를 사용할 땐 상위 레이어에 시그모이드 활성화 함수를 사용한다.
출력이 0 1 값이고, 이진 분류를 사용하는 경우, 시그모이드는 출력층에 대해 자연스러운 선택

1과 2의 단점 : z가 매우 크거나 작으면 이 함수의 기울기의 도함수가 매우 작아지는데, 이는 기울기 하강 속도가 느려질 수 있다.

3) 정류된 선형 단위(Relu) ; 기본 선택 a = max(0, z)

단점 : z가 음수일 때 도함수 = 0

4) Leaky Relu : Relu의 단점 보완 a = max(0.01z, z)

3과 4의 장점 : 활성화 함수의 도함수인 z의 많은 공간에 대해 활성화 함수의 기울기가 0과 매우 다르고, 빠른 학습을 한다.
- 함수의 기울기가 0이 되어 학습 속도가 느려지는 효과가 적고, z 범위의 절반에 대해 값의 기울기가 0이라는 것을 알고 있다.

[비선형 활성화 함수]

$$z^{[1]} = W^{[1]}x + b^{[1]}$$
$$a^{[1]} = g^{[1]}(z^{[1]})$$
$$z^{[2]} = W^{[2]}a^{[1]} + b^{[2]}$$
$$a^{[2]} = g^{[2]}(z^{[2]})$$

IF 활성화 함수가 없다면, a[1] = z[1] => g(z) = z (선형 활성화 함수)
a[1] = z[1] = W[1] * X + b[1]
a[2] = z[2] = W[2] * a[1] + b[2] = W[2] * (W[1] * X + b[1]) + b[2]
= W[2] * W[1] * X + W[2] * b[1] + b[2] = W' * X + b'
신경망은 입력의 선형 함수 출력 => 선형의 숨겨진 층은 쓸모가 없다 => 표현력이 없다.
이는 회귀 문제에 대한 머신러닝을 할 때 출력층에서 사용

[Gradient Descent or Neural Networks] 역전파

Back propagation:

$dZ^{[2]} = A^{[2]} - Y$ $\qquad Y = [y^{(1)}\ y^{(2)} \dots, y^{(m)}]$

$dW^{[2]} = \frac{1}{m} dZ^{[2]} A^{[1]T}$ $\qquad (n^{[2]},)$

$db^{[2]} = \frac{1}{m}$ np.sum($dZ^{[2]}$, axis=1, keepdims=True) $\qquad (n^{[2]}, 1)$

$dZ^{[1]} = \underbrace{W^{[2]T} dZ^{[2]}}_{(n^{[1]}, m)} * \underbrace{g^{[1]\prime}(Z^{[1]})}_{(n^{[1]}, m)}$ element-wise product

$dW^{[1]} = \frac{1}{m} dZ^{[1]} X^T$

$db^{[1]} = \frac{1}{m}$ np.sum($dZ^{[1]}$, axis=1, keepdims=True)

$(n^{[1]}, 1) \qquad (n^{[1]},)$

[Random Initialization]

매개변수에 대한 가중치 0으로 초기화한 후 기울기 하강하면 작동하지 않을 것이다.

가중치는 매우 작은 무작위 값으로 초기화하는 것을 선호 ex) 0.01

가중치가 너무 크면 활성화 값을 계산할 때, 기울기 하강이 매우 느릴 것이다.

w 값이 매우 크면, 훈련 초기에도 z의 값이 클 확률이 높다.
-> 탄젠트나 시그모이드가 포화되어 학습 속도가 느려진다.

[다중 layer] 단일 -> m번 훈련 (1 -> m)

w[l].shape : (n[l], n[l-1]) / b[l].shape : (n[l], 1) / a[l] = z[l] .shape(n[l], 1)

함수들은 작지만 심층 신경망을 계산되며 작다는 것은 숨겨진 유닛의 수가 적다는 것을 의미
그러나 얕은 네트워크로 동일한 함수를 계산하려고 하면, 숨겨진 레이어가 충분하지 않다면 계산하기 위해 숨겨진 유닛이 기하급수적으로 더 많이 필요할 수 있다.